

Trabalho de Estatística (Parte 1)

Análise Exploratória e Amostragem

Aluno: Filipe Utrini Amim Braga

1. Dados

Escolhi a base de dados `diabetes_risk` disponível no Kaggle.

2. População, amostra e amostragem

2.1 População

População de interesse: **Pessoas em acompanhamento e avaliação de risco para diabetes.**

2.2 Tamanho da amostra

2.2.1 Variável escolhida para definir o tamanho da amostra

Variável escolhida: `fasting_blood_sugar`.

Justificativa: Trata-se de uma variável essencial para o diagnóstico e acompanhamento do diabetes.

2.2.2 Escolha do erro amostral

Escolhi um erro amostral $E = 1,7$, que é aproximadamente 1% da média da variável.

Esse erro representa a máxima diferença tolerada entre a média da amostra e a verdadeira média populacional.

2.2.3 Fórmula usada para o tamanho da amostra

Calculei a variância amostral de `fasting_blood_sugar`:

$$s^2 = 1469.705.$$

Fixando $z = 1,96$, o tamanho da amostra é:

$$n = \frac{z^2 \cdot s^2}{E^2} = \frac{1,96^2 \cdot 1469.705}{1,7^2} \approx 1953.$$

2.3 Seleção aleatória da amostra

Depois de definido o tamanho da amostra, foi usada uma seleção aleatória utilizando a semente (*seed*) 1234 para escolher as 1953 observações utilizadas no trabalho.

3. Escolha e classificação das variáveis

Selecionei as seguintes variáveis da base de dados:

Tabela 1: Variáveis escolhidas e suas classificações

Variável	O que representa	Tipo	Justificativa
age	Idade dos indivíduos	Numérica contínua	É uma medição de tempo de vida.
fasting_blood_sugar	Açúcar no sangue em jejum	Numérica contínua	É uma medição clínica contínua.
hba1c	Hemoglobina glicada	Numérica contínua	É uma medição clínica contínua.
stress_level	Nível de estresse do paciente	Numérica discreta	É uma medição contínua discretizada (aceita apenas valores inteiros de 1 a 10).
physical_activity_level	Nível de atividade física	Categórica ordinal	Apresenta categorias ordenáveis.
diabetes_risk	Risco de diabetes	Categórica ordinal	Apresenta categorias ordenadas por gravidade.
gender	Gênero do indivíduo	Categórica nominal	Apresenta categorias sem ordem.

4. Variável categórica nominal

4.1 gender

Indica o gênero do indivíduo.

4.1.1 Tabela de distribuição de frequências

Tabela 2: Distribuição da variável **gender**

Gênero	n_i	f_i	N_i	F_i
Homem	967	0.4951	967	0.4951
Mulher	971	0.4972	1938	0.9923
Outro	15	0.0077	1953	1.0000
Total	1953	1.00		

4.2 Gráfico de setores




Figura 1: Gráfico de setores da variável **gender**

A variável **gender** apresenta uma distribuição praticamente igual entre homens e mulheres. As mulheres correspondem à maior proporção, representando 49,72%, seguidas de perto pelos homens, que compõem 49,51%. A categoria “Outro” representa uma parcela mínima da amostra, com apenas 0,77%.

O gráfico de setores mostra essa divisão quase igual os gêneros masculino e feminino, demonstrando que a amostra sorteada é equilibrada em relação ao gênero.

5. Variável categórica ordinal

5.1 physical_activity_level

Mede a intensidade de atividade física praticada pelos indivíduos.

5.1.1 Tabela de distribuição de frequências

Tabela 3: Distribuição da variável `physical_activity_level`

Nível	n_i	f_i	N_i	F_i
Ativo	661	0.3385	661	0.3385
Moderado	637	0.3261	1298	0.6646
Sedentário	655	0.3354	1953	1.0000
Total	1953	1.0		

5.1.2 Gráfico de setores

Gráfico de Setores de Atividade Física




Figura 2: Gráfico de setores da variável `physical_activity_level`

A distribuição dos níveis de atividade física é homogênea entre as três categorias observadas. A categoria mais frequente é a dos indivíduos **Ativos**, correspondendo a 33,85% da amostra. Em seguida, figuram os indivíduos **Sedentários**, que somam 33,54%, e os de nível **Moderado**, representando 32,61%. Analisando a frequência acumulada, observa-se que 66,46% da amostra possui nível de atividade física até o grau Moderado.

O gráfico de setores mostra a divisão quase em três partes iguais, o que revela que os hábitos de exercício físico estão uniformemente distribuídos.

5.2 diabetes_risk

Mede o nível de risco de desenvolvimento ou presença de diabetes nos indivíduos.

5.2.1 Tabela de distribuição de frequências

Tabela 4: Distribuição da variável **diabetes_risk**

Nível de Risco	n_i	f_i	N_i	F_i
Alto	291	0.1490	291	0.1490
Médio	487	0.2494	778	0.3984
Baixo	1175	0.6016	1953	1.0000
Total	n	1,00	100%	-

5.2.2 Gráfico de barras ou de setores

Gráfico de Setores de Risco




Figura 3: Gráfico de setores da variável **diabetes_risk**

A variável **diabetes_risk** apresenta maior concentração na categoria de **Baixo** risco, compreendendo mais da metade da amostra analisada com 60,16% dos indivíduos. A categoria de risco **Moderado** representa aproximadamente um quarto dos pacientes, com 24,94%, enquanto a categoria de **Alto** risco corresponde à menor fatia da amostra, englobando 14,90% dos casos.

Analisando as frequências acumuladas sob a perspectiva clínica, observa-se que 39,84% da amostra encontra-se em patamares de risco Moderado a Alto, demandando maior atenção em estratégias de acompanhamento e prevenção. O gráfico de setores ilustra claramente essa predominância do grupo de baixo risco, mantendo um contingente expressivo de indivíduos em faixas de risco intermediário e elevado.

6. Variável numérica discreta

6.1 stress_level

A variável discreta escolhida representa a escala de estresse percebido pelo paciente (números inteiros variando de 1 a 10).

6.2 Tabela de frequências

Tabela 5: Distribuição da variável **stress_level**

Nível de Estresse	n_i	f_i	N_i	F_i
1	43	0.0220	43	0.0220
2	61	0.0312	104	0.0532
3	141	0.0722	245	0.1254
4	248	0.1270	493	0.2524
5	335	0.1715	828	0.4239
6	332	0.1700	1160	0.5939
7	347	0.1777	1507	0.7716
8	202	0.1034	1709	0.8751
9	126	0.0645	1835	0.9396
10	118	0.0604	1953	1.0000
Total	1953	1.0000		

6.3 Histograma




Figura 4: Histograma da variável (`stress_level`)

A variável `stress_level` apresenta maior concentração nos valores intermediários. Os níveis de estresse mais frequentes na amostra são o nível 7, representando 17,77%, o nível 5 com 17,15% e o nível 6 com 17,00%. Juntos, os níveis de 5 a 7 concentram mais da metade dos indivíduos analisados (51,92%).

Por outro lado, os extremos da escala possuem frequências menores: o nível 1 representa apenas 2,20% e o nível 2 representa 3,12%. Pela frequência acumulada, constata-se que 77,16% dos indivíduos possuem nível de estresse igual ou inferior a 7.

O histograma possui um formato unimodal e aproximadamente simétrico no centro, com um leve declínio nas pontas.

7. Variáveis numéricas contínuas

7.1 age

Mede a idade dos indivíduos contidos na amostra.

7.1.1 Medidas resumo

Tabela 6: Medidas resumo da variável **age**

Medida	Valor
Tamanho da amostra	1953
Média	44.3594
Variância amostral	106.6986
Desvio-padrão amostral	10.3295
Mínimo	18
1° quartil (Q_1)	37
Mediana	45
3° quartil (Q_3)	52
Máximo	73
Amplitude	55
Assimetria	-0.3315
Curtose	-0.2169

Cálculo das medidas:

- **Média ($\bar{x}$):** Centro de massa dos dados, dada pela soma de todas as observações dividida pelo tamanho da amostra:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{18 + 52 + \cdots + 73}{1953} \approx 44,36 \text{ anos.}$$

- **Variância Amostral (s^2) e Desvio-Padrão (s):** Medem a dispersão dos dados em torno da média.:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \approx 106,70, \quad s = \sqrt{s^2} = \sqrt{106,70} \approx 10,33 \text{ anos.}$$

- **Mediana (Md) e Quartis (Q_1, Q_3):** A mediana é o valor central que divide os dados ao meio. Como $n = 1953$ é ímpar, $Md = x_{((1953+1)/2)} = x_{(977)} = 45$ anos. Os quartis indicam os cortes de 25% ($Q_1 = 37$) e 75% ($Q_3 = 52$).
- **Assimetria e Curtose:** A assimetria mede o desvio em relação à simetria, e a curtose mede o achatamento da distribuição.

7.1.2 Histograma e Boxplot




Figura 5: Histograma da variável age

A média de idade dos indivíduos é de 44,36 anos com desvio-padrão de 10,33 anos. A média e a mediana estão extremamente próximas, o que indica uma distribuição com boa simetria.

Metade dos indivíduos da amostra possui idade entre 37 anos (Q_1) e 52 anos (Q_3), resultando em um intervalo interquartilico ($IQR = Q_3 - Q_1$) de 15 anos. A amplitude total da idade na amostra é de 55 anos, variando de 18 a 73 anos.

A assimetria de $-0,3315$ (levemente negativa) indica uma cauda suavemente mais longa à esquerda (presença discreta de jovens), enquanto a curtose excessiva de $-0,2169$, próxima de zero, indica que a distribuição possui formato bastante semelhante à curva Normal, sem concentração excessiva nem outliers.

7.2 fasting_blood_sugar


Mede os níveis de glicemia em jejum dos indivíduos.

7.2.1 Medidas resumo

Tabela 7: Medidas resumo da variável `fasting_blood_sugar`

Medida	Valor
Tamanho da amostra	1953
Média	169.1577
Variância amostral	1453.4945
Desvio-padrão amostral	38.1247
Mínimo	86
1º quartil (Q_1)	146
Mediana	164
3º quartil (Q_3)	189
Máximo	400
Amplitude	314
Assimetria	0.8734
Curtose	2.0002

7.2.2 Histograma e Boxplot

Figura 6: Histograma / Boxplot da variável `fasting_blood_sugar`

A glicose em jejum apresenta média de 169,16 mg/dL e mediana de 164,00 mg/dL. A diferença entre a média e mediana sugere a presença de outliers puxando a média para cima.

A dispersão dos dados é alta, demonstrada por um desvio-padrão de 38,12 mg/dL e variância de 1453,49. O intervalo central da amostra compreende valores entre 146,00 mg/dL (Q_1) e 189,00 mg/dL (Q_3). A amplitude total é de 314 mg/dL.

A assimetria positiva de 0,8734 revela uma cauda longa à direita. A curtose excessiva de 2,0002 aponta uma distribuição com as caudas pesadas. No Boxplot, essa característica fica

evidenciada pelo grande número de outliers na direita, chegando a 400 mg/dL), indicando um grupo de pacientes com quadros severos de hiperglicemia.

7.3 hba1c

Mede o nível da hemoglobina glicada no sangue.

7.3.1 Medidas resumo

Tabela 8: Medidas resumo da variável **hba1c**

Medida	Valor
Tamanho da amostra	1953
Média	6.8800
Variância amostral	0.7143
Desvio-padrão amostral	0.8452
Mínimo	5.1
1° quartil (Q_1)	6.3
Mediana	6.8
3° quartil (Q_3)	7.3
Máximo	11.6
Amplitude	6.5
Assimetria	0.9310
Curtose	2.0559

7.3.2 Histograma e Boxplot




Figura 7: Histograma / Boxplot da variável **hba1c**

A variável hemoglobina glicada (**hba1c**) possui média de 6,88% e mediana de 6,80%. Como ambas estão acima do valor de referência de 5,7%, nota-se uma amostra predominantemente composta por indivíduos pré-diabéticos ou diabéticos.

O desvio-padrão é de 0,85% com variância de 0,71, indicando baixa variabilidade absoluta em torno da média. A metade central dos dados situa-se entre 6,30% (Q_1) e 7,30% (Q_3). A variação total observada vai de um mínimo de 5,1% a um máximo de 11,6%.

O coeficiente de assimetria de 0,9310 e a curtose excessiva de 2,0559 indicam um pico central mais alto com cauda à direita. O Boxplot mostra claramente diversos outliers no extremo superior, destacando pacientes com descontrole glicêmico grave que destoam da maioria da amostra.